بخش دوم: 2.1

import data

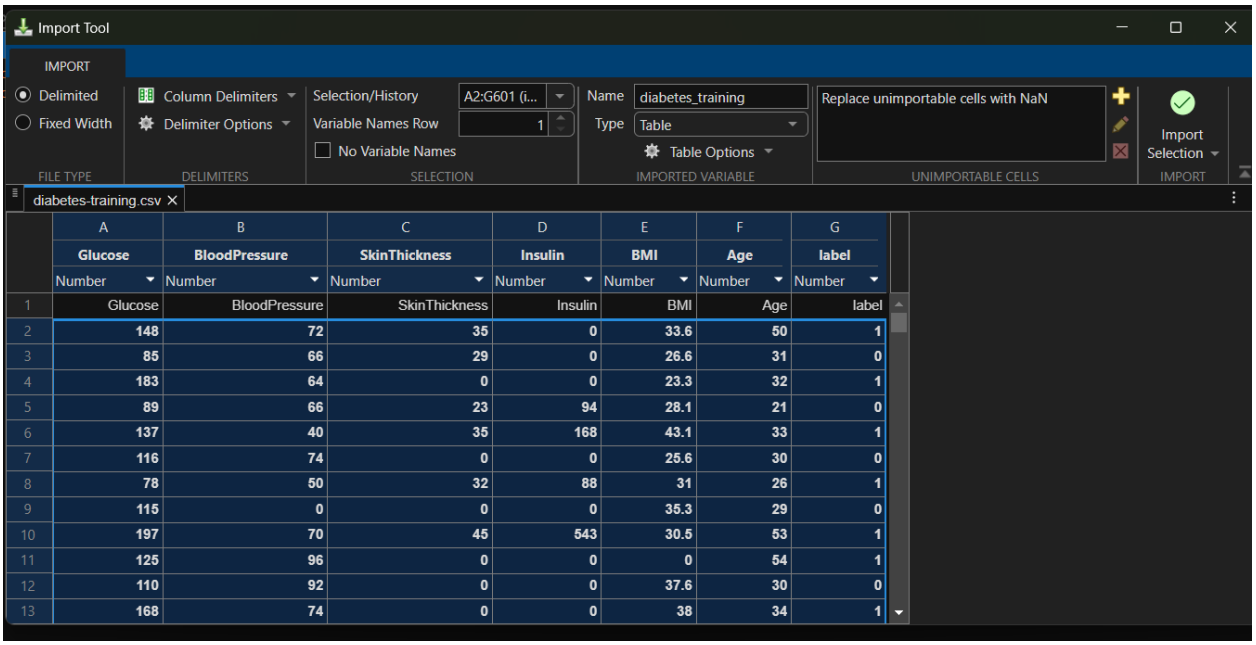

	A	B	C	D	E	F	G
	Glucose	BloodPressure	SkinThickness	Insulin	BMI	Age	label
	Number	Number	Number	Number	Number	Number	Number
1	Glucose	BloodPressure	SkinThickness	Insulin	BMI	Age	label
2	148	72	35	0	33.6	50	1
3	85	66	29	0	26.6	31	0
4	183	64	0	0	23.3	32	1
5	89	66	23	94	28.1	21	0
6	137	40	35	168	43.1	33	1
7	116	74	0	0	25.6	30	0
8	78	50	32	88	31	26	1
9	115	0	0	0	35.3	29	0
10	197	70	45	543	30.5	53	1
11	125	96	0	0	0	54	1
12	110	92	0	0	37.6	30	0
13	168	74	0	0	38	34	1

اضافه کردن متغیر دیتاست:

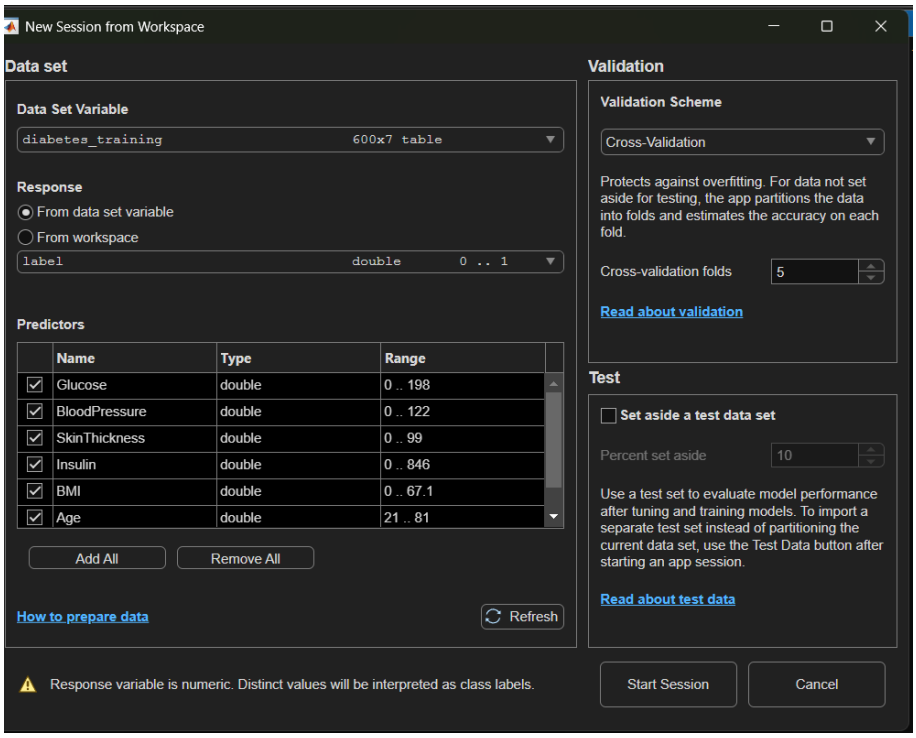

اسکتر پلات دیتاست:

خلاصه ای از مدل با تمام فیچر ها:

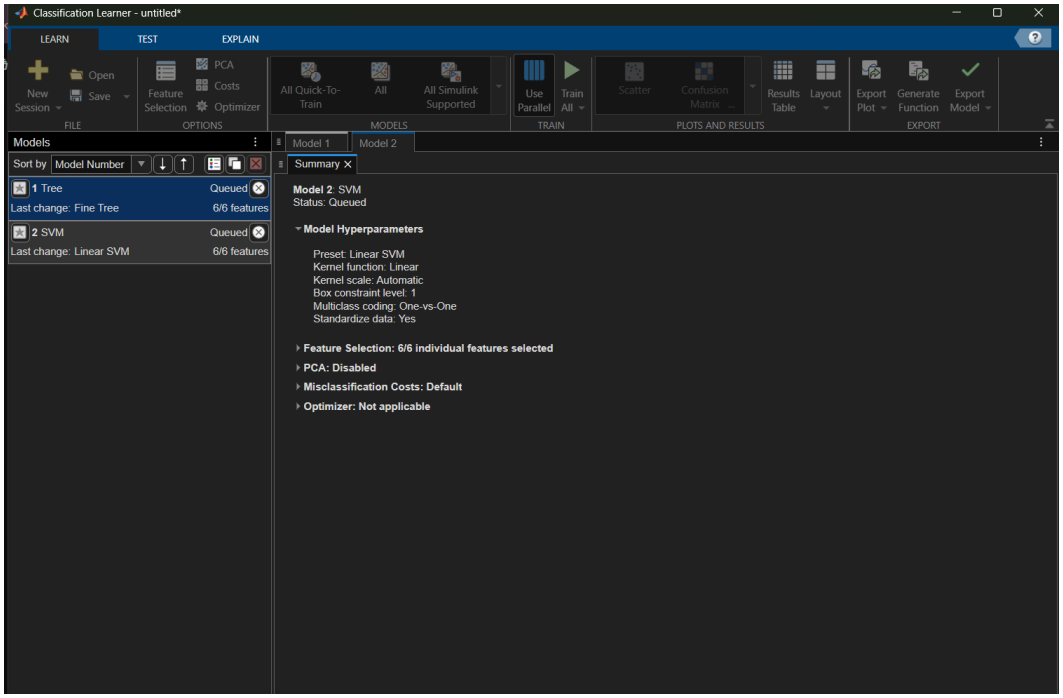

دقت و ماتریس کانفیوژن: که برابر با 76.8 درصد است.

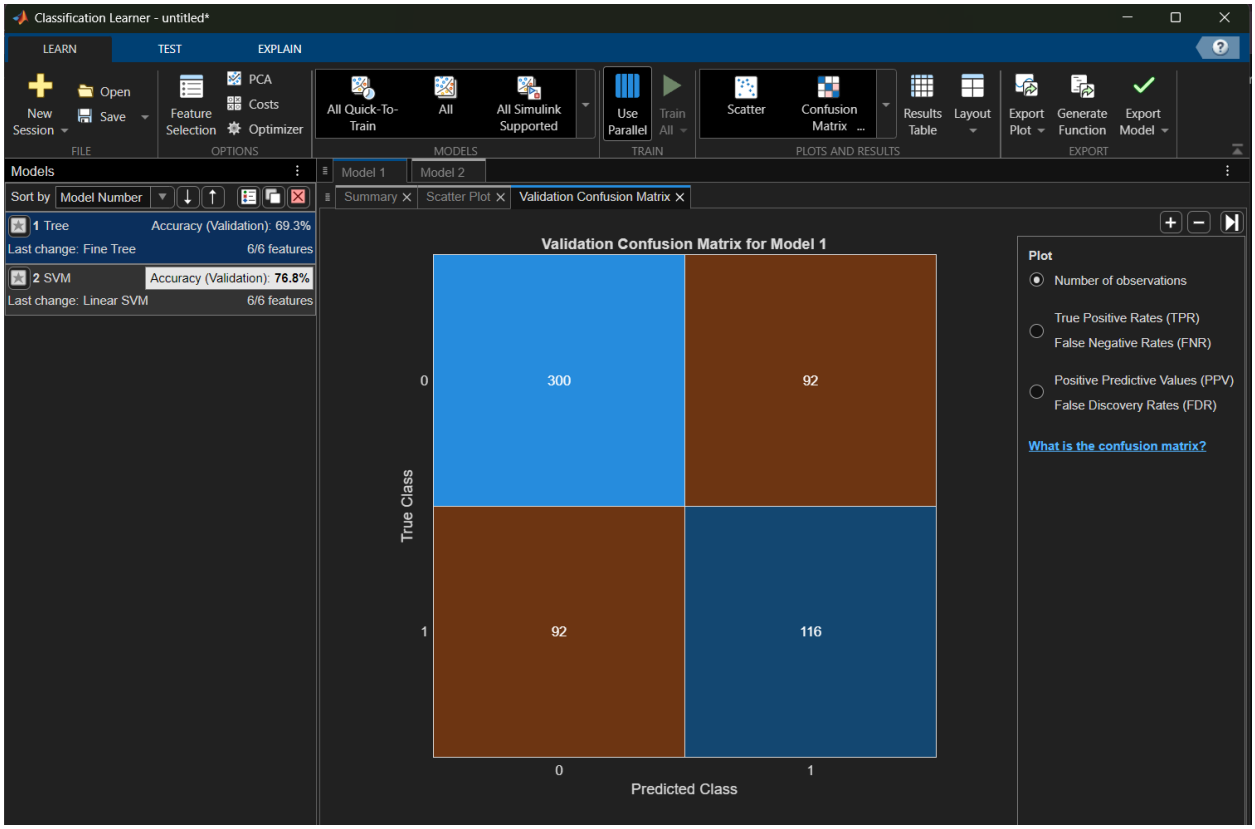

2.2: فیچر سلکشن:

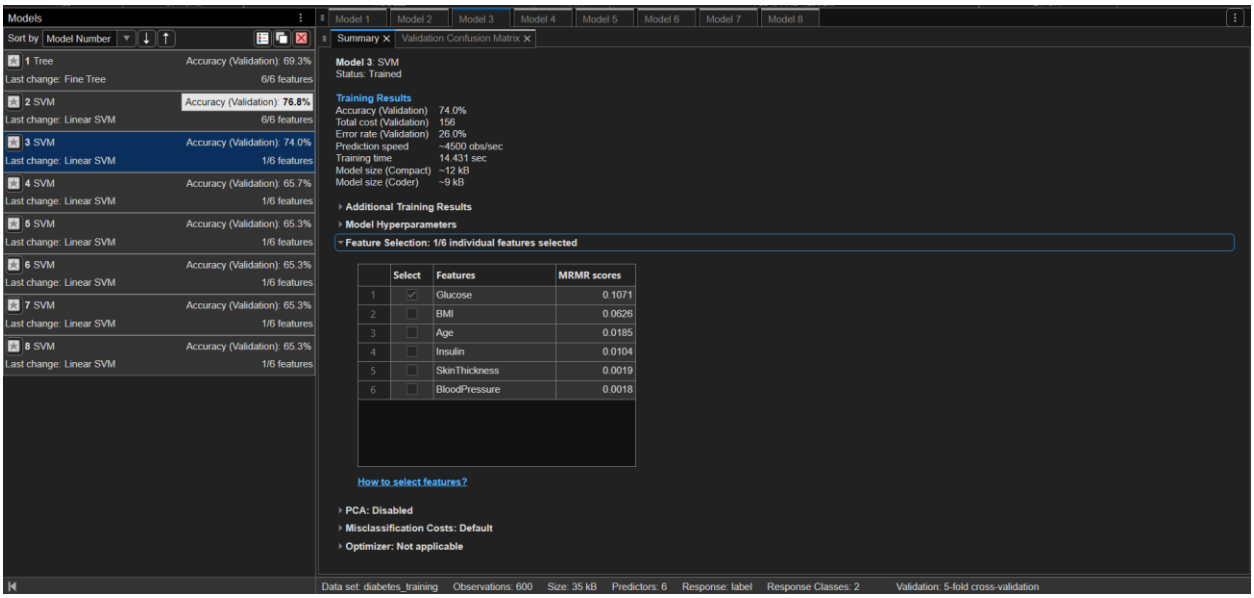

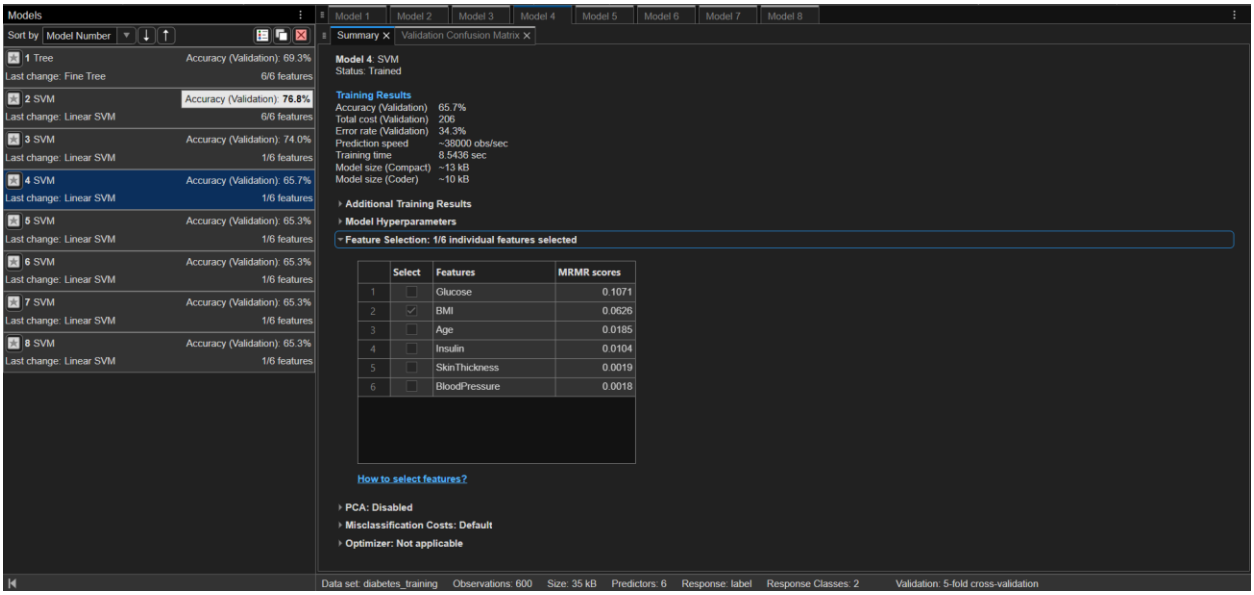

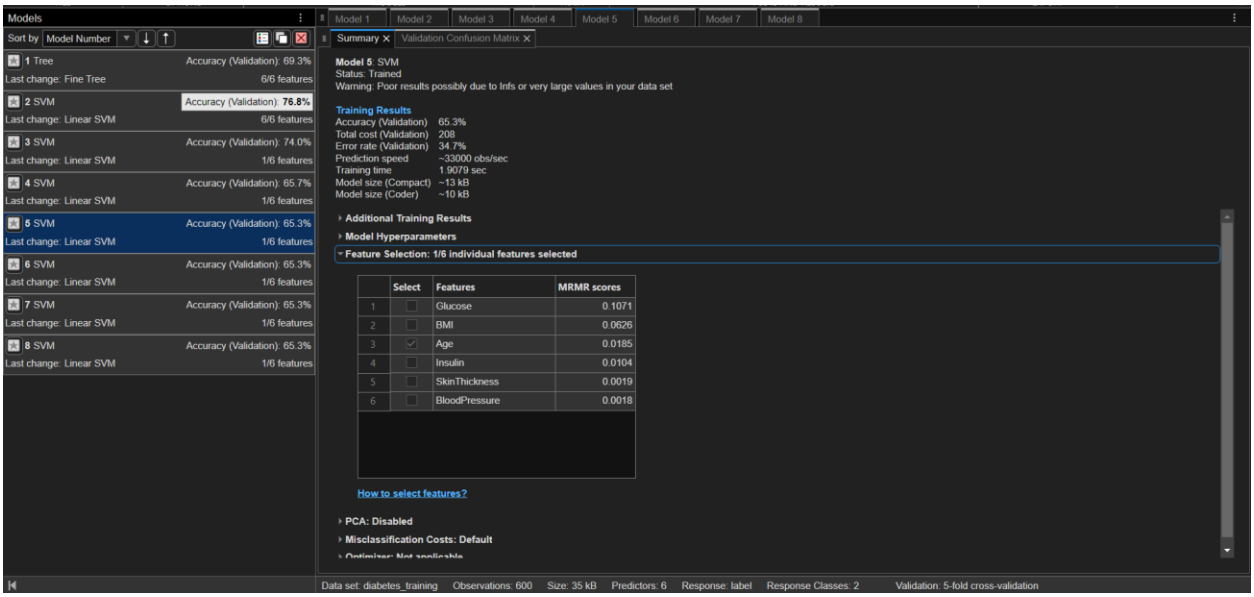
Models
Sort by Model Number
1 Tree Accuracy (Validation): 69.3%
Last change: Fine Tree 6/6 features
2 SVM Accuracy (Validation): 76.8%
Last change: Linear SVM 6/6 features
3 SVM Accuracy (Validation): 74.0%
Last change: Linear SVM 1/6 features
4 SVM Accuracy (Validation): 65.7%
Last change: Linear SVM 1/6 features
5 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
6 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
7 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
8 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
Model 1 Model 2 Model 3 Model 4 Model 5 Model 6 Model 7 Model 8
Summary Validation Confusion Matrix
Model 5: SVM
Status: Trained
Warning: Poor results possibly due to Infs or very large values in your data set
Training Results
Accuracy (Validation) 65.3%
Total cost (Validation) 208
Error rate (Validation) 34.7%
Prediction speed ~33000 obs/sec
Training time 1.9079 sec
Model size (Compact) ~13 kB
Model size (Coder) ~10 kB
Additional Training Results
Model Hyperparameters
Feature Selection: 1/6 individual features selected
Select Features MRMR scores
1 Glucose 0.1071
2 BMI 0.0626
3 Age 0.0185
4 Insulin 0.0104
5 SkinThickness 0.0019
6 BloodPressure 0.0018
How to select features?
PCA: Disabled
Misclassification Costs: Default
Data set: diabetes_training Observations: 600 Size: 35 kB Predictors: 6 Response: label Response Classes: 2 Validation: 5-fold cross-validation

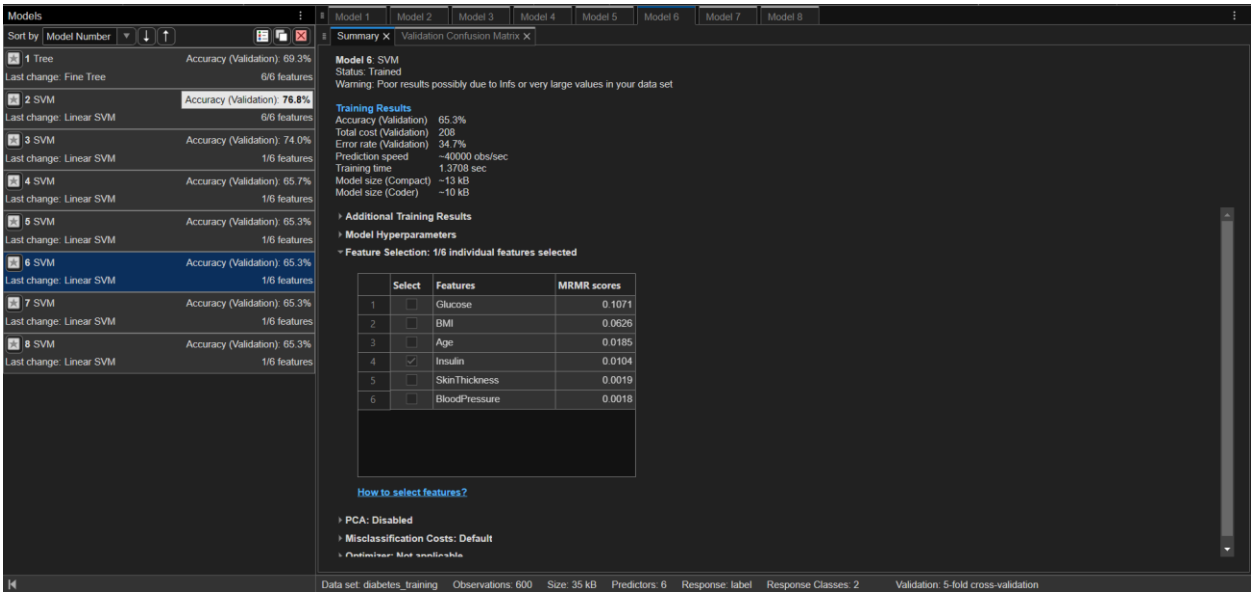
Models
Sort by Model Number
1 Tree Accuracy (Validation): 69.3%
Last change: Fine Tree 6/6 features
2 SVM Accuracy (Validation): 76.8%
Last change: Linear SVM 6/6 features
3 SVM Accuracy (Validation): 74.0%
Last change: Linear SVM 1/6 features
4 SVM Accuracy (Validation): 65.7%
Last change: Linear SVM 1/6 features
5 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
6 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
7 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
8 SVM Accuracy (Validation): 65.3%
Last change: Linear SVM 1/6 features
Model 1 Model 2 Model 3 Model 4 Model 5 Model 6 Model 7 Model 8
Summary Validation Confusion Matrix
Model 6: SVM
Status: Trained
Warning: Poor results possibly due to Infs or very large values in your data set
Training Results
Accuracy (Validation) 65.3%
Total cost (Validation) 208
Error rate (Validation) 34.7%
Prediction speed ~40000 obs/sec
Training time 1.3708 sec
Model size (Compact) ~13 kB
Model size (Coder) ~10 kB
Additional Training Results
Model Hyperparameters
Feature Selection: 1/6 individual features selected
Select Features MRMR scores
1 Glucose 0.1071
2 BMI 0.0626
3 Age 0.0185
4 Insulin 0.0104
5 SkinThickness 0.0019
6 BloodPressure 0.0018
How to select features?
PCA: Disabled
Misclassification Costs: Default
Data set: diabetes_training Observations: 600 Size: 35 kB Predictors: 6 Response: label Response Classes: 2 Validation: 5-fold cross-validation

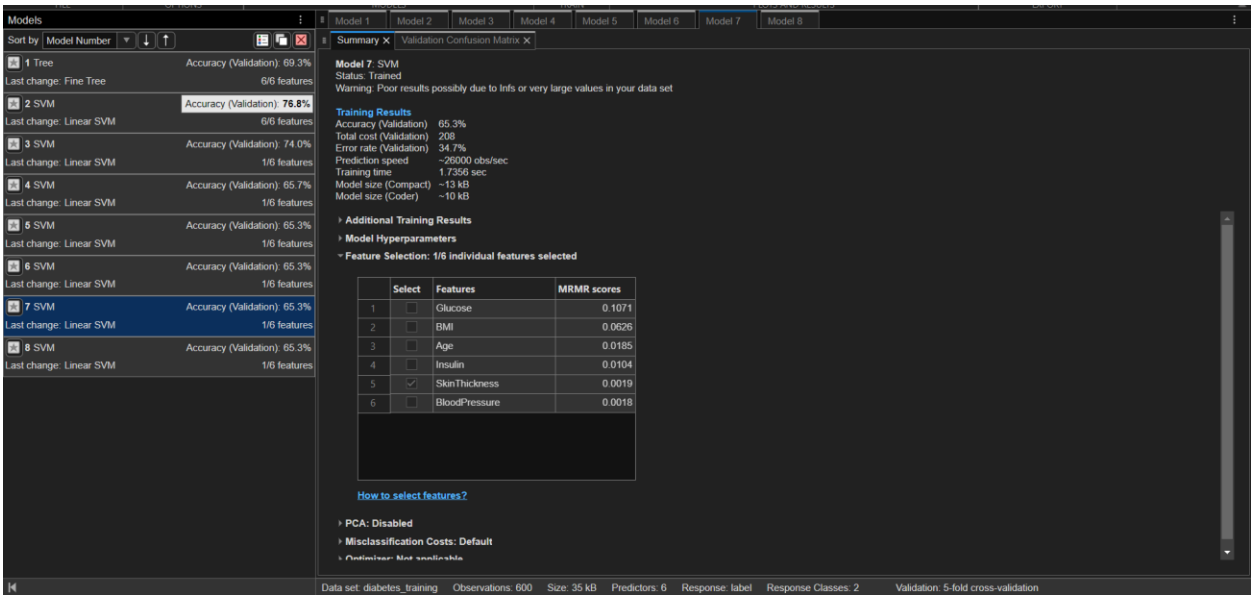

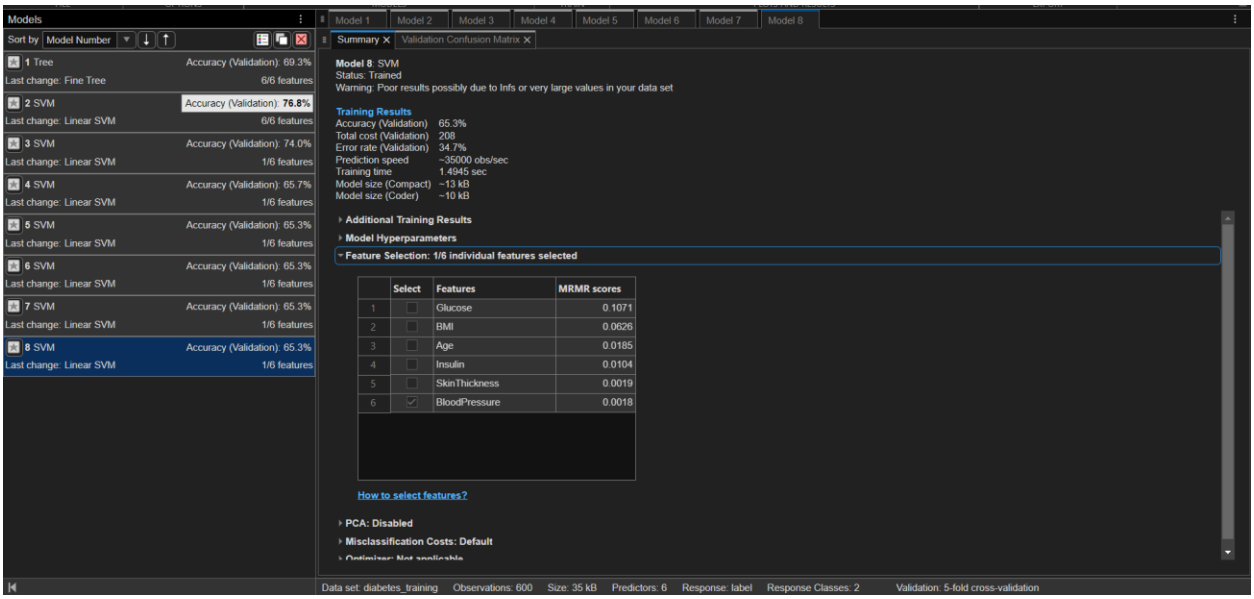

۱ .رسیدن به "دقت پایه"

۴ ویژگی (فشار خون، ضخامت پوست و انسولین و سن) به تنهایی قدرت تفکیک‌کنندگی کافی برای مدل Linear SVMرا ندارند.

- **توضیح :**در این دیتاست، حدود **۶۵.۳٪** افراد سالم (بدون دیابت) هستند.
- وقتی یک ویژگی ضعیف (مثل فشار خون) را به مدل می‌دهیم و مدل نمی‌تواند خط صافی پیدا کند که بیماران را جدا کند، تصمیم می‌گیرد برای **همه** پیش‌بینی کندسالم

- وقتی برای همه پیش‌بینی کند «سالم»، دقیقاً ۶۵.۳٪ از جواب‌ها درست در می‌آید (چون ۶۵.۳٪ واقعا سالم بوده‌اند).
- بنابراین، تمام ویژگی‌های ضعیف، همین عدد ثابت (دقت شانسی) را می‌دهند.
- بر اساس امار های بدست امده ویژگی گلوکز با درصد 74 درصد بالاترین درصد را بدست اورد پس مهم ترین فیچر هست.

:2.3

untitled.m

D:\term5\SS\taklif\ca\4\p2\untitled.m

```
if ~exist('diabetes_training', 'var')
    error('لطفا ابتدا فایل diabetes-training را ایمپورت کنید');
end


predicted_labels = trainedModel.predictFcn(diabetes_training);

actual_labels = table2array(diabetes_training(:, end));
correct_predictions = sum(predicted_labels == actual_labels);
total_samples = length(actual_labels);

train_accuracy = (correct_predictions / total_samples) * 100;

disp(['Manual Training Accuracy: ', num2str(train_accuracy), '%']);
```

Command Window

```
Error in untitled (line 11)
predicted_labels = trainedModel2.predictFcn(diabetes_training);
                   ^^^
```

.دلیل تفاوت بین **دقت آموزش (Training Accuracy)** و **دقت اعتبارسنجی (Validation Accuracy)**است:

1. **عددی که در اپلیکیشن ۷۶.۸٪ :**این عدد Validation Accuracyاستتنظیمات پیش‌فرض شامل "Cross Validation Folds" است. اپلیکیشن داده‌ها را (مثلاً به ۵ بخش) تقسیم کرده، با ۴ بخش آموزش داده و با ۱ بخش تست کرده است. این عدد تخمینی از عملکرد مدل روی داده‌های جدید است.
2. **عددی که با کد ۷۷.۵٪ :**این عدد Training Accuracyاست. مدل را روی کل ۶۰۰ داده آموزش دادیم و سپس از مدل خواستیم همان ۶۰۰ نفر را پیش‌بینی کند .چون ماشین این داده‌ها را قبلاً دیده است، معمولاً کمی بهتر عمل می‌کند (چون الگوهای خاص همین داده‌ها را یاد گرفته است).

:2.4

```
untitled.m ×   untitled2.m ×   +
D:\term5\SS\taklif\ca\4\p2\untitled2.m

if ~exist('diabetes_validation', 'var')
    error('لطفا ابتدا فایل diabetes-validation را ایمپورت کنید');
end

predicted_val = trainedModel.predictFcn(diabetes_validation);

actual_val = table2array(diabetes_validation(:, end));

correct_val = sum(predicted_val == actual_val);
total_val = length(actual_val);

test_accuracy = (correct_val / total_val) * 100;

disp(['Test (Validation) Accuracy: ', num2str(test_accuracy), '%']);
```

```
Command Window
>> untitled2
Test (Validation) Accuracy: 78%
>>
```

نتیجه گیری:بالا بودن جزئی دقت ارزیابی (۷۸٪) نسبت به دقت آموزش (۷۷.۵٪) نشان‌دهنده Generalization بسیار خوب مدل است و بیانگر آن است که مدل دچار Overfitting نشده است. همچنین به دلیل تعداد کم نمونه‌های تست این تغییرات جزئی ناشی از توزیع آماری نمونه‌ها طبیعی است.